

2026 전기

Physical AI 졸업과제 중간 보고서

LeRobot SO-101을 활용한 지능형 로봇팔 제어

팀명

키자니아 패밀리

팀원

학번	이름	이메일
202355561	여채언	codjs2659@pusan.ac.kr
202355536	문여원	myw0422@pusan.ac.kr
202355562	옥소미	osm0071@pusan.ac.kr

지도교수: 김원석 분과: C

Contents

1	과제 개요	3
1.1	연구 배경 및 필요성	3
1.2	과제 목표	3
1.3	기대 결과	3
2	요구조건 및 제약사항 분석에 대한 수정사항	4
2.1	초기 요구조건	4
2.2	변경된 요구조건	4
2.3	제약사항 및 대응 방안	5
2.3.1	Orin Nano 정책 추론 제한 및 서버 추론 구조 채택	5
2.3.2	Orin Nano의 통신·제어 전용 운영	5
2.3.3	서버-엣지 네트워크 지연 대응	5
2.3.4	도커 기반 평가 환경 재현	5
3	시스템 설계 상세화 및 변경 내역	6
3.1	시스템 설계 상세화	6
3.1.1	전체 시스템 구성	6
3.1.2	하드웨어 구성	7
3.1.3	소프트웨어 구성	7
3.1.4	시스템 동작 시나리오	7
3.1.5	데이터 설계	8
3.2	착수 설계 대비 변경 내역	8
3.2.1	카메라 대수 및 배치 변경	8
3.2.2	추론 연산 위치 변경	8
3.2.3	추론 방식 변경	8
3.2.4	모델 종류 확장	8
3.2.5	데이터 소스 확장	9
4	보고 시점까지의 과제 수행 내용	10
4.1	하드웨어 및 소프트웨어 개발 환경 구축	10
4.2	GPU 서버 및 통신 파이프라인 연동	10
4.3	데이터 수집 및 초기 모방학습 수행	10
4.4	MuJoCo 기반 시뮬레이션 환경 구축	11
4.5	성능 향상을 위한 추가 실험 조치	11
5	중간 실험 및 결과 분석	12
5.1	실험 목적 및 배경	12
5.2	실험 환경 및 평가 지표	12
5.3	카메라 2대 뷰 조합별 결과 분석 (ACT 모델 적용 / Stack 50 에피소드)	12
5.3.1	Top + Wrist 조합	12
5.3.2	Top + Side 조합	12
5.3.3	Side + Wrist 조합 (조작 성능 Best)	12
5.4	카메라 2대 조합 및 ACT 모델 전환에 따른 지연시간 단축 결과	12
5.5	결론	13
6	문제점 및 해결 과정	14
6.1	로봇 관절 유격 문제	14
6.2	데이터 수집 및 품질 문제	14
6.3	블록 인식 및 조명 문제	14
7	갱신된 과제 추진 계획	15
7.1	향후 개발 일정	15
7.2	핵심 마일스톤	16

7.3	위험 요소 및 대응 방안	16
7.3.1	Simulation-to-Real 차이	16
7.3.2	Simulation 환경 구축 지연	16
7.3.3	강화학습 보상 설계 문제	16
8	구성원별 역할 및 진척도	17
8.1	공동 수행 업무	17
8.2	전체 진척도	17

1 과제 개요

1.1 연구 배경 및 필요성

Physical AI는 로봇이나 자율주행차처럼 실제 환경에서 동작하는 시스템이 주변을 인식(Perception)하고 이해한 뒤, 상황을 판단(Decision)하여 행동(Control)하는 기술이다. 기존의 로봇이 정해진 동작을 반복하는 자동화 장비에 가까웠다면, Physical AI 기반 로봇은 이미지·영상·센서 데이터로 물체의 위치와 상태를 파악하고, 이를 로봇이 실제로 수행할 수 있는 동작으로 연결하여 상황에 맞게 스스로 행동을 조정한다.

본 졸업과제는 이러한 Physical AI의 개념을 실제 로봇팔 제어에 적용하는 과제이다. 종목 2 “LeRobot SO-101을 활용한 지능형 로봇팔 제어”는 테이블 위에 무작위로 놓인 블록을 집어 지정된 영역으로 옮기고, 나아가 안정적으로 쌓아 올리는 것을 목표로 하는 Pick & Stack 문제를 대상으로 한다. 이는 단순한 로봇팔 구동을 넘어 비전 기반 상태 인식 → 정책 학습 기반 행동 생성 → 로봇팔 제어가 하나의 파이프라인으로 통합되어야 하는 과제이다.

특히 블록의 위치가 매 시행마다 달라지는 환경에서 작업을 수행해야 하므로, 정해진 궤적을 재생하는 방식으로는 한계가 있다. 인식 결과가 실제 동작으로 이어지고 다양한 초기 조건에서도 일반화되어 동작하는 정책을 학습·검증하는 과정이 필요하며, 이는 VLA(Vision-Language-Action) 기반 정책 모델을 실물 로봇 환경에 적용해 보는 기초 연구로서 의의를 가진다.

1.2 과제 목표

과제는 난이도에 따라 두 개의 미션으로 구성되며, 최종적으로는 두 미션의 완성도와 수행 효율을 함께 달성하는 것을 목표로 한다. (블록 규격·제한 시간 등 세부 수치는 변경된 요구조건 v2.0 기준이며, 자세한 변경 내역은 2장에서 다룬다.)

구분	목표
1차 미션	LeRobot SO-101 로봇팔이 경기장에 무작위로 배치된 5개의 블록($4 \times 4 \times 2$ cm, 서로 다른 색)을 카메라로 인식하고, 각 블록을 지정 영역(20×10 cm) 안으로 옮긴다. (제한 시간 3분)
2차 미션	지정 영역으로 옮긴 블록을 탑처럼 위로 쌓아 올린다. 놓는 위치의 정밀도와 적재 후 균형을 함께 고려하여 무너지지 않도록 쌓는다. (제한 시간 5분)
최종 미션	5개 블록 중 가능한 많은 블록을 정확히 옮기고 안정적으로 적재하며, 불필요한 동작을 줄여 수행 시간을 단축한다. 이를 위해 카메라로 블록의 위치를 파악하고, 정책 모델이 추론한 행동을 로봇 관절 제어 명령으로 변환하여 이동 경로와 그리퍼 동작을 제어한다.

1.3 기대 결과

인식-행동 연결 과정의 이해: 카메라로 블록의 위치를 파악하고 로봇팔을 움직여 물체를 집고 옮기는 전 과정을 구현함으로써, 인식 결과가 실제 물리적 동작으로 이어지는 과정을 이해한다.

정책 학습 역량 확보: Tele-operation으로 수집한 expert demonstration을 활용한 모방학습으로 기본 Pick & Place / Pick & Stack 동작을 확보하고, 이후 강화학습으로 블록 배치 정확도·적재 성공 여부·수행 시간 등을 보상 기준에 반영하여 정책을 개선한다. 이로써 다양한 초기 조건에서도 안정적으로 과제를 수행하도록 학습 과정을 설계하는 방법을 익힌다.

응용 확장성: 블록 이동·적재 과제에서 확보한 인식·정책 학습·로봇 제어 기술은 물류 자동화, 정리정돈, 조립 보조, 교육용 로봇 실습 등 다양한 분야로 확장될 수 있으며, 실물 로봇 환경에 VLA 기반 정책 모델을 적용하는 기초 연구로서의 가치를 가진다.

2 요구조건 및 제약사항 분석에 대한 수정사항

2.1 초기 요구조건

항목	요구조건
주제	Pick & Stack — 블록 집기 및 순차 적재
블록	5개, $5 \times 5 \times 2$ cm, 넓은 면(5×5)이 바닥을 향하도록 배치
블록 준비	팀별 직접 준비 (크기 규격만 준수하면 색상·재질·무게 무관, 각 Dimension 5 mm 초과 불가)
지정 영역	20×10 cm
경기장	A3 용지 (420×297 mm)
제한 시간	총 5분 내 두 미션 수행
1차 목표	5개 블록을 지정 영역 내에 가져다 두기
2차 목표	블록을 탐처럼 위로 쌓기 (도전 과제)
성공 인정	블록이 5초 이상 안정적으로 유지될 경우 성공
제어 기법	규칙 기반·비전 기반·모방학습 등 제한 없음, 팀별 자유
연산 기기	별도 지정 없음 (착수보고서에서는 학습·추론용 RTX 4090 PC + 제어용 Jetson Orin Nano를 팀 자체 구성으로 계획)

2.2 변경된 요구조건

항목	v1.5 (초기)	v2.0 (변경)
블록 크기	$5 \times 5 \times 2$ cm	$4 \times 4 \times 2$ cm
블록 준비	팀별 직접 준비	학과 배부 블록 사용 (5개 색상 상이)
초기 블록 위치	평가자가 무작위 결정	평가자가 무작위 결정, 모든 팀 동일
제한 시간	두 미션 통합 5분	1차 3분 / 2차 5분 (미션별 분리)
1차 성공 기준	지정 영역 내 배치	선 안에 위치(선 걸침 2cm까지 허용), 세로로 세우거나 일부 겹쳐도 선 안이면 인정, 단 쌓기는 불인정
지정 영역	20×10 cm, 경계선 10/20 mm	내부 기준 20×10 cm, 경계선 최대 2 cm, 로봇 끝(카메라 제외) 기준 25 cm 지점에 배치
경기장	A3 용지	배부된 체크보드 또는 A3 용지 위에 영역 표시
모델 사용 기기	지정 없음	배부된 Jetson Orin Nano로 서버 컴퓨터와 통신하며 사용. 추론(모델 연산)은 제공되는 평가 서버 컴퓨터에서 수행
실행 환경	팀별 자유	통일성을 위해 평가 서버 컴퓨터 제공. 모든 팀은 로컬에서 학습·세팅 후 도커 이미지를 구워, 이미지만 평가 서버로 옮겨 컨테이너를 생성해 사용 (nvidia-driver-580-open 제공 예정)
서버 통신 방식	지정 없음	ROS / TCP / UDP 자유 선택 및 혼용 가능
카메라	높이·각도 자율	높이·각도 자율, 대수 제한 없음 (추가 구매·사용 가능)

2.3 제약사항 및 대응 방안

2.3.1 Orin Nano 정책 추론 제한 및 서버 추론 구조 채택

문제

v2.0에서는 Jetson Orin Nano를 평가 서버와 통신하는 용도로만 사용하고, 정책 추론은 평가 서버에서 수행하도록 규정한다. 또한 Orin Nano에서는 CUDA 기반 PyTorch 환경과 최신 LeRobot 제어 환경의 Python 버전이 달라, 추론과 로봇 제어를 하나의 환경에서 동시에 구성하기 어렵다.

대응

정책 추론과 로봇 제어를 분리하고, LeRobot의 Async Inference(RobotClient-PolicyServer) 구조를 적용한다. Orin Nano는 로봇·카메라 입출력과 action 실행을 담당하고, 평가 서버는 SmolVLA 정책 추론을 수행한다. 이를 통해 대회 요구조건을 충족하면서 Python 및 CUDA 환경 충돌 문제를 제거한다.

역할	장비	담당 작업
RobotClient	Jetson Orin Nano	observation 송신, action 수신 및 로봇 제어
PolicyServer	평가 서버	SmolVLA 정책 모델 추론

2.3.2 Orin Nano의 통신·제어 전용 운영

문제

Orin Nano가 추론을 수행하지 않는 대신, 관측 데이터 송신과 action 실행이 실시간으로 안정적으로 이루어져야 한다. 동기식 추론 구조에서는 서버 추론 중 로봇이 대기하여 제어 지연이 발생할 수 있다.

대응

Orin Nano에는 Python 3.12 기반 LeRobot 제어 환경만 구성한다. 또한 비동기 추론을 적용해 현재 action chunk를 실행하는 동안 서버가 다음 chunk를 미리 계산하도록 한다. 겹치는 action은 weighted average 등의 aggregation 방식으로 병합해 idle frame과 제어 지연을 줄인다.

2.3.3 서버-엣지 네트워크 지연 대응

문제

관측 데이터와 action이 네트워크를 통해 전달되므로 통신 지연과 대역폭 변화가 action queue의 안정성에 영향을 줄 수. 특히 v2.0에서는 1차 미션 제한 시간이 3분으로 단축되어 지연 관리가 중요하다.

대응

ROS, TCP, UDP 중 실시간 제어에 적합한 통신 방식을 선정하고, actions per chunk, chunk size threshold, fps 등의 비동기 추론 파라미터를 실제 네트워크 환경에 맞게 조정한다.

2.3.4 도커 기반 평가 환경 재현

문제

v2.0에서는 팀별 실행 환경을 도커 이미지로 제작해 통일된 평가 서버에서 실행해야 하므로, 개발 환경과 평가 환경의 차이로 인한 재현 실패 가능성이 있다.

대응

개발 초기부터 도커 컨테이너 기반으로 학습·추론 환경을 구성한다. 평가 서버의 nvidia-driver-580-open과 호환되는 CUDA 및 PyTorch 버전을 사용하고, 최종 코드와 의존성을 도커 이미지에 포함해 평가 서버에서도 동일한 환경을 재현한다.

3 시스템 설계 상세화 및 변경 내역

3.1 시스템 설계 상세화

3.1.1 전체 시스템 구성

본 과제는 LeRobot SO-101 매니퓰레이터를 대상으로, 사람의 Tele-operation 시연 데이터를 학습한 정책이 실물 환경에서 Pick-and-Place 및 Stack 태스크를 자율 수행하도록 하는 것을 목표로 한다. 이를 위해 (1) 시연 데이터 수집, (2) 모방학습(IL) 기반 정책 학습, (3) LeRobot 비동기 추론(Async Inference) 기반 실물 실행의 3단계 파이프라인을 구축한다.

전체 시스템은 (A) 실물 로봇 · 센서 · 시뮬레이션이 위치하는 물리 로봇 환경, (B) 통신 브리지 역할의 Jetson Orin Nano(Edge), (C) 학습과 추론을 담당하는 RTX 4090 PC(Compute)의 세 계층으로 구성된다. 추론 연산은 전적으로 RTX 4090이 담당하며, Orin은 관측 송신과 행동 수신 · 중계만 수행한다. 이는 온보드 연산 부담을 낮추고, 고성능 GPU에서 대형 정책을 실시간 추론하기 위한 구성이다.




Figure 1: 전체 시스템 아키텍처 및 데이터 흐름 (수집, 학습, 비동기 추론)

데이터 흐름은 세 가지다.

- ① 데이터 수집에서는 리더 장치로 팔로워(SO-101)를 직접 제어해 태스크를 시연하고, 이때의 시각 관측 · 언어 지시 · 행동 궤적을 에피소드로 기록한다.
- ② 학습은 수집 데이터와 시뮬레이션 데이터를 통합해 정책을 오프라인으로 미세조정한다.
- ③ 비동기 추론은 배포 단계로, 카메라 관측이 Orin을 거쳐 4090의 Policy Server로 전달되고, 서버가 생성한 Action Chunk가 다시 팔로워로 중계되어 실행된다.

3.1.2 하드웨어 구성

구분	항목	사양 / 설정	비고
매니플레이터	LeRobot SO-101 (Follower)	6-DoF, 그리퍼 1축, 제어 주파수 30 Hz	실제 태스크 수행 주체
입력 장치	Tele-operation 리더	리더-팔로워 대응 관절 매핑	데이터 수집 시연용
비전	Wrist Camera	640 x 480 / 30 fps	그리퍼 근접 시점, occlusion 보완
비전	Top Camera	640 x 480 / 30 fps	작업대 전역 시점
Edge	Jetson Orin Nano	관측 송신 · 행동 중계(추론 미수행)	통신 브리지
Compute	RTX 4090 PC	VRAM 24 GB, 학습 · 추론 담당	Policy Server 구동
통신	Orin ↔ 4090	Wi-Fi 인터넷 연결, Tailscale 기반 가상 사설망, Tailscale IP를 이용한 장치 간 통신	Orin에서 카메라 영상 · 로봇 상태 전송, RTX 4090 PC에서 생성된 Action Sequence 수신

3.1.3 소프트웨어 구성

구분	소프트웨어 및 기술	주요 설정	역할
운영 환경	Ubuntu Linux, Python	Python 가상환경 사용	로봇 제어 및 학습 프로그램 실행 환경
로봇 프레임워크	Hugging Face LeRobot	SO-101 Leader/Follower 설정	Tele-operation, 데이터 기록, 정책 학습 및 평가, 로봇 제어
딥러닝 프레임워크	PyTorch, CUDA	RTX 4090 GPU 가속	모델 학습 및 정책 추론
영상 입력	OpenCV	Top · Wrist Camera, 640×480, 30 FPS	작업 공간 및 그리퍼 주변 영상 수집
데이터 관리	LeRobot Dataset, Hugging Face Hub	Episode 단위 저장	영상, 관절 상태, action 및 task 정보 관리
학습 정책	Diffusion Policy	Observation 2 step, Horizon 32, Action 15 step	연속적인 로봇 action sequence 생성
학습 정책	ACT	Action Chunk 기반	Diffusion Policy와 성능 비교
학습 정책	SmolVLA	이미지 · 언어 · 로봇 상태 입력	복수 task의 언어 지시 기반 수행 검증
비동기 추론	LeRobot Async Inference	Policy Server와 로봇 클라이언트 분리	추론 지연 중에도 연속적인 로봇 제어 수행
시뮬레이션	MuJoCo	향후 적용 예정	다양한 초기 환경 및 실패 상황 데이터 생성
추가 학습	Reinforcement Learning	향후 적용 예정	모방학습 정책의 성공률 개선

3.1.4 시스템 동작 시나리오

한 사이클은 다음 순서로 진행된다.

- 1) 데이터 수집 : 운영자가 리더 장치로 팔로워를 조작해 태스크를 시연한다. 시각 관측(2개 카메라), 언어 지시, 관절 · 그리퍼 행동 궤적을 시간 동기화하여 에피소드로 저장한다.
- 2) 학습(오프라인) : 수집 에피소드와 MuJoCo 시뮬레이션 데이터를 통합해 SmolVLA · ACT · Diffusion Policy를 각각 미세조정하고, 검증셋에서 성공률을 측정해 정책 가중치를 확정한다.
- 3) 비동기 추론(배포) : 실행 시 카메라 관측이 Orin을 통해 4090 Policy Server로 전송된다. 서버는 관측을 받아 정책을 추론해 Action Chunk를 생성하고, 로봇은 현재 Chunk를 실행하는 동안 서버는 다음 Chunk를 미리 추론한다. 이 중첩 구조 덕분에 추론 지연이 동작의 끊김으로 이어지지 않는다.

- 4) 종료 · 평가 : 성공 기준 충족 여부를 판정하고 성공률 · 소요 시간 등 지표를 기록한다. 실패 사례는 로그를 남겨 데이터 보강 또는 정책 개선에 반영한다.

3.1.5 데이터 설계

- Tele-operation Episode 구조 : 각 에피소드는 (관측, 지시, 행동) 시퀀스를 타임스텝 단위로 시간 동기화 하여 구성한다.
- 구성 요소 : Visual Observation(Wrist/Top 이미지), Language Instruction(태스크 지시문), Action Trajectory(관절그리퍼 목표값).
- Real-Sim 데이터 통합: 실환경에서 수집한 데이터와 MuJoCo 시뮬레이션 데이터를 동일한 데이터 스키마로 변환 · 정렬하여 통합 학습셋을 구성한다. Real 데이터와 Sim 데이터의 혼합 비율은 향후 비교 실험을 통해 최적값을 도출하고 단계적으로 조정할 예정이다.
- 규모: Pick-and-Place와 Stack 태스크별 목표 에피소드 수는 현재 확정하지 않았다. 초기 학습 결과와 성공률 변화를 분석한 뒤, 성능 향상 추세와 데이터 수집 비용을 고려하여 적절한 에피소드 수를 결정할 예정이다.

3.2 착수 설계 대비 변경 내역

3.2.1 카메라 대수 및 배치 변경

- 변경 전: Wrist, Top, Side 카메라 총 3대 사용
- 변경 후: Wrist와 Top 카메라 총 2대 사용
- 변경 사유: 카메라 3대를 사용할 경우 영상 처리량이 증가하여 전처리 시간과 정책 추론 지연이 커졌다. 또한 2대의 카메라만으로도 작업 공간과 파지 지점을 충분히 관찰할 수 있었다. 카메라 2대 조합에 대한 비교 실험 결과, Wrist와 Top으로 결정하였다.

3.2.2 추론 연산 위치 변경

- 변경 전: Jetson Orin Nano에서 정책 추론 수행
- 변경 후: RTX 4090 PC에서 정책 추론을 수행하고, Jetson Orin Nano는 통신 및 로봇 제어를 담당
- 변경 사유: Jetson Orin Nano에서 지원되는 PyTorch 버전과 LeRobot 추론 명령 실행에 필요한 Python 3.12 및 라이브러리 요구사항이 호환되지 않았다. 또한 Orin Nano의 연산 성능만으로는 정책의 안정적인 실시간 추론 성능 확보가 어려워, 추론 기능을 RTX 4090 PC로 이전하고 장치별 역할을 분리하였다.

3.2.3 추론 방식 변경

- 변경 전: 동기식 추론
- 변경 후: 비동기 추론
- 변경 사유: 동기식 추론에서는 새로운 action을 생성하는 동안 로봇의 동작이 일시적으로 멈추거나 제어 주기가 불안정해질 수 있다. 이를 개선하기 위해 정책 추론과 로봇 제어를 분리하고, 미리 생성된 action sequence를 순차적으로 실행하는 비동기 추론 방식을 적용하였다.

3.2.4 모델 종류 확장

- 변경 전: 단일 정책 중심의 학습 및 평가
- 변경 후: SmolVLA, ACT, Diffusion Policy 비교
- 변경 사유: 하나의 정책만으로 성능을 평가하는 방식에서 벗어나, 정책 구조에 따른 Pick-and-Place 및 Stack 성능 차이를 비교하기 위해 모델 범위를 확장하였다. 작업 성공률, 추론 속도, 동작 안정성 등을 기준으로 최종 적용 모델을 선정할 예정이다.

3.2.5 데이터 소스 확장

- 변경 전: 실환경 Tele-operation 데이터만 사용
- 변경 후: 실환경 데이터와 MuJoCo 시뮬레이션 데이터 통합
- 변경 사유: 실환경 데이터만으로는 다양한 물체 배치와 실패 상황을 충분히 확보하기 어렵고 데이터 수집 비용도 크다. 이에 MuJoCo에서 생성한 시뮬레이션 데이터를 동일한 데이터 스키마로 변환하여 통합하고, 데이터 다양성과 정책의 일반화 성능을 높이고자 하였다. Real 데이터와 Sim 데이터의 혼합 비율은 향후 실험 결과를 바탕으로 조정할 예정이다.

4 보고 시점까지의 과제 수행 내용

4.1 하드웨어 및 소프트웨어 개발 환경 구축

- Jetson Orin Nano 세팅: 제어용 OS 이미지 설치 및 최신 LeRobot 환경 구성 완료.
- 하드웨어 안정성 확보: Leader-Follower Arm 간 Tele-operation 구동 테스트 및 다중 카메라 포트 매핑 완료.

4.2 GPU 서버 및 통신 파이프라인 연동

- 인프라 구축: RTX 4090 기반 학습/추론용 서버 PC에 LeRobot 및 Hugging Face 환경 세팅 완료.
- 비동기 통신 적용: LeRobot 공식 Async Inference 프레임워크를 사용하여 서버-Jetson Orin Nano 간 실시간 Action 값 전송 파이프라인 구축.

4.3 데이터 수집 및 초기 모방학습 수행



Figure 2: 경기장 환경

- 초기 데이터 확보: 카메라 2대 환경에서 1차(Pick & Place) 미션에 대한 전문가 시연 데이터 100 에피소드 수집.
- 학습 결과: 100 에피소드 기반의 SmolVLA 모방학습 적용 결과, 블록 배치가 정면이거나 간섭이 없는 단순 케이스에서는 1차 미션 Task 성공을 달성함 (약 4분 소요).
- 한계점: 구동 속도가 느리고 간헐적인 헛손질이 발생함. 특히 블록이 사각지대 등 어려운 위치에 배치될 경우 Gripper 파지 실패율이 급상승하는 한계를 보임.
- 카메라 3대 확장 시 문제 발생: 위치 인식 정밀도를 높이려 카메라를 3대로 증설했으나, 오히려 데이터 처리량 폭증으로 인한 연산 Lag 및 Latency가 발생하여 로봇 행동이 저하됨.

4.4 MuJoCo 기반 시뮬레이션 환경 구축

- Scene 생성: 차후 시뮬레이션을 활용한 대량 데이터 수집 및 강화학습(RL) 적용을 위해 가상 물리 엔진인 MuJoCo 기반의 작업 환경(Scene) 구축 완료.




Figure 3: MuJoCo scene

4.5 성능 향상을 위한 추가 실험 조치

- 대응 방향: 카메라 3대 체제는 자연 한계가 있기 때문에 카메라 2대만 활용하기로 결정. 카메라 2대 기반의 최적 시야 조합 테스트를 재진행함 (5장 기술).
- 타 모델 비교 실험 (진행 중): SmolVLA 외에 ACT, Diffusion Policy 모델 간의 성능 비교 실험을 진행 중임.

5 중간 실험 및 결과 분석

5.1 실험 목적 및 배경

- 배경: SmolVLA 모델 기반으로 카메라를 3대까지 확장했을 때 발생한 심각한 연산 병목(Inference Time 241.55 ms, Deserialization Time 약 100 ms) 문제를 해결하기 위함.
- 목적: 제어 Lag을 최소화하고 실시간 제어 주기를 정상화하기 위해 카메라 2대 구성에서의 뷰(화각 및 배치) 조합별 성능 최적화 실험을 수행함.
- 모델 변경: 실험의 안정적인 구동을 위해 기존 SmolVLA 대신 상대적으로 경량인 ACT 모델을 적용하여 최적의 카메라 배치를 탐색함.

5.2 실험 환경 및 평가 지표

- 실험 환경: ACT 모델 적용, 카메라 2대 배치 변경 테스트, Stack(2차 미션) 50 에피소드 수집 및 학습
- 평가 지표: 블록 이동/Stack(2차 미션) 성공률, 평균 수행 시간, 파지 실패율, Stack(2차 미션) 안정성, 지연시간

5.3 카메라 2대 뷰 조합별 결과 분석 (ACT 모델 적용 / Stack 50 에피소드)

5.3.1 Top + Wrist 조합

- 현상: 블록 위 허공을 짚는 헛손질 빈도 증가.
- 원인: 수직 Top 뷰 특성상 Z축 깊이 왜곡 발생 및 블록 파지 시 Wrist 카메라가 Gripper 한쪽을 가리는 시야 차폐 현상 유발.

5.3.2 Top + Side 조합

- 현상: 시작 자세에서 로봇이 구동되지 않고 멈추는 프리징 현상 발생 (물리적 자극 필요).
- 원인: End-effector 근방의 정밀 시각 정보를 제공하는 Wrist 카메라 부재로 인해 초기 행동에 대한 모델 Confidence 저하.

5.3.3 Side + Wrist 조합 (조작 성능 Best)

- 현상: 블록 파지 및 Stack(2차 미션) 이동까지 가장 부드럽고 정확하게 수행하나, 최종 Release 시간헐적 실패.
- 분석: Side 뷰에서 Gripper 파지 동작이 가려짐 없이 선명하게 포착되며, 측면 관측으로 Z축(높이) 정밀도가 우수하여 최적의 조작 성능 도출.

5.4 카메라 2대 조합 및 ACT 모델 전환에 따른 지연시간 단축 결과

구분	기존 환경 (SmolVLA + 카메라 3대)	변경 환경 (ACT + 카메라 2대)	개선 결과
Inference Time	241.55 ms	약 11 ms	대폭 감소
Deserialization Time	약 100 ms	약 0.6 ms	대폭 감소

- 분석: SmolVLA 대신 ACT 모델을 채택하고 카메라 대수를 2대로 최적화함으로써, 지연 시간이 대폭 개선됨.

5.5 결론

- 조작 성능은 'Side + Wrist'가 우수했으나, 최종적으로 '낮은 각도의 Top + Wrist' 조합 채택.
- 사유: Side 뷰는 경기장 외곽의 불필요한 배경 노이즈가 과도하게 포함됨. 이는 향후 Sim-to-Real 환경 구축 시 배경 구현 및 Domain Randomization 적용 복잡도를 지나치게 높이는 한계가 있음. 시뮬레이션 환경과의 정합성을 위해 뷰를 경기장 내부로 제한하면서 화각 차폐를 최소화하는 낮은 각도의 Top 뷰로 최종 절충함.

6 문제점 및 해결 과정

6.1 로봇 관절 유격 문제

- 문제 상황 : 반복적인 데이터 수집 과정에서 로봇 관절을 장시간 움직이면 관절 체결 나사가 점차 풀리면서 유격이 발생하였다. 이로 인해 Leader Arm에서 동일한 제어 명령을 입력하더라도 Follower Arm의 실제 관절 이동 범위와 말단 위치가 달라져, 데이터의 일관성과 동작 재현성이 저하되는 문제가 발생하였다.
- 해결 방안 : 관절 체결 상태를 주기적으로 점검하고, 본드를 사용하여 나사를 고정하였다. 또한 데이터 수집 전 로봇의 유격과 캘리브레이션 상태를 확인하는 점검 절차를 추가할 예정이다.

6.2 데이터 수집 및 품질 문제

- 문제상황 : 초기에는 정상적으로 태스크를 수행한 성공 demonstration 위주로 데이터를 수집하였다. 그러나 성공 상태만 포함된 데이터로 학습할 경우, 실제 추론 중 블록을 놓치거나 파지 위치가 어긋나는 등 학습 데이터에 포함되지 않은 상태에 진입했을 때 정책이 적절하게 복구하지 못하는 문제가 발생하였다.
- 해결방안 : 이를 개선하기 위해 단순한 실패 궤적을 그대로 학습시키기보다, 정책 실행 중 사람이 개입하여 잘못된 동작을 수정하고 정상 상태로 복구하는 Human-in-the-Loop 기반 DAgger 데이터 수집 방식을 적용할 예정이다. LeRobot에서는 `lerobot-rollout --strategy.type=dagger`를 통해 자율 동작 중 사람의 개입 구간과 복구 동작을 수집할 수 있으며, 이를 기존 demonstration 데이터와 함께 사용하여 정책을 반복적으로 개선할 수 있다.
- 주요 수집 대상은 파지 위치 오차, 블록 미끄러짐, 블록 낙하, 목표 위치 이탈 및 적재 실패 이후의 복구 동작으로 구성할 예정이다.

6.3 블록 인식 및 조명 문제

- 문제 상황 : 실환경에서는 조명의 밝기와 방향, 그림자, 카메라 노출, 주변 배경 등에 따라 입력 영상의 색상과 명암이 크게 달라진다. 이로 인해 동일한 블록과 작업 공간이라도 학습 데이터와 실제 추론 영상 사이에 차이가 발생하여 블록 인식 및 위치 판단 성능이 저하될 수 있다.
- 해결 방안 : MuJoCo 시뮬레이션 데이터 생성 과정에서 조명 밝기와 방향, 카메라 위치, 배경, 물체 색상 및 초기 배치 등을 다양하게 변화시키는 Domain Randomization을 적용할 예정이다. 이를 통해 정책이 특정 조명이나 환경에 과도하게 의존하지 않도록 하고, 실제 환경 변화에 대한 강건성과 일반화 성능을 향상하고자 한다.

7 갱신된 과제 추진 계획

7.1 향후 개발 일정

기간	추진 단계	주요 개발 내용	목표 및 산출물
7월	Simulation 및 강화학습 적용 가능성 검토	• SO-101 로봇, 블록, 작업 공간, 카메라를 포함한 기본 Simulation 환경 구성 • 단일 블록 Pick-and-Place 태스크 구현 및 정상 동작 확인 • 블록 위치·방향·배치 간격을 변화시켜 Simulation 데이터 생성 • 조명, 배경, 색상, 질감, 카메라 위치 및 각도를 변화시키는 Visual Domain Randomization 검토 • 블록 질량, 마찰계수, 관절 감쇠, 제어 오차 및 통신 지연을 변화시키는 Dynamics Randomization 검토 • 모방학습 모델별 적용 가능한 강화학습 알고리즘 조사 • Diffusion Policy-DPPO·FPO, ACT-PPO·SAC, SmolVLA-PPO·DPO·Flow 기반 강화학습의 적용 가능성 비교	• 기본 Simulation 환경 • Simulation 데이터 생성 방법 • Domain Randomization 설정안 • 모방학습 모델별 강화학습 적용 가능성 분석
8월	강화학습 기반 정책 최적화 검토	• Tele-operation 데이터로 학습한 모방학습 정책을 초기 정책으로 활용 • 기존 정책의 반복적인 실패 행동을 개선하는 방향으로 강화학습 수행 • 단일 블록 Pick-and-Place 태스크를 대상으로 보상 함수 설계 • 그리퍼와 블록 사이의 거리 감소, 파지 성공, 목표 영역 도달에 대한 보상 적용 • 적용 가능성이 확인되면 Pick-and-Stack 태스크로 확장 • 접근, 파지, 이동, 정렬, 적재 단계별 보상 구조 검토 • 실제 환경에서 반복적으로 실패할 경우 HIL-SERL 방식의 사람 개입 및 실패 복구 데이터 수집 검토	• Reward 설계 문서 • 강화학습 Fine-tuning 정책 • Pick-and-Place 강화학습 적용 결과 • 사람 개입 및 Recovery Data 수집 방안
9월	최종 안정화 및 성능 비교	• Simulation 및 강화학습 실험 결과를 바탕으로 최종 정책 선정 • 블록 파지, 이동 및 적재 과정의 안정성 개선 • 관절 명령의 급격한 변화 and 불필요한 움직임 감소 • 로봇과 블록 사이의 충돌, 그리퍼 미끄러짐 및 블록 낙하 감소 • 정책 추론 속도와 서버-로봇 간 통신 지연 최적화 • 연속 Episode 수행 시 누적 오차와 실패 복구 가능성 점검 • 최종 실험 결과 정리 및 보고서·발표자료 작성	• 최종 정책 및 데모 시스템 • 방법론별 성능 비교표 • 최종 안정화 결과 • 최종 보고서 및 발표자료

7.2 핵심 마일스톤

단계	핵심 마일스톤	주요 산출물
1	SO-101 기반 Simulation 환경 구성	로봇, 블록, 작업 공간 및 카메라가 포함된 Simulation 환경
2	다양한 블록 배치와 환경 조건 구현	Simulation 데이터 생성 환경
3	Visual · Dynamics Domain Randomization 적용	랜덤화 항목 및 파라미터 설정안
4	Simulation Episode 데이터 생성	Simulation Dataset
5	모방학습 모델별 강화학습 적용 가능성 분석	강화학습 방법론 비교 결과
6	Pick-and-Place 태스크의 보상 함수 설계	Reward 설계 문서
7	모방학습 정책 기반 강화학습 적용 실험	강화학습 Fine-tuned Policy
8	실제 로봇의 실패 및 복구 데이터 수집	Human Intervention 및 Recovery Dataset
9	Real-only, Sim-only, Sim+Real, 강화학습 정책 비교	방법론별 성능 평가표
10	최종 정책 안정화 및 문서화	최종 모델, 보고서 및 발표자료

7.3 위험 요소 및 대응 방안

7.3.1 Simulation-to-Real 차이

Simulation에서 학습한 정책은 실제 환경의 조명, 카메라 왜곡, 마찰, 관절 유격 및 제어 지연으로 인해 성능이 저하될 수 있다.

이를 해결하기 위해 실제 로봇과 작업 환경의 크기 및 배치를 측정하여 Simulation에 반영하고, 조명, 질감, 카메라 위치, 블록 질량, 마찰계수 등을 일정 범위 내에서 무작위로 변경한다. 또한 Simulation 데이터만 사용하는 것이 아니라 실제 Tele-operation 데이터를 함께 활용하거나, Simulation으로 사전학습한 뒤 실제 데이터로 Fine-tuning한다.

7.3.2 Simulation 환경 구축 지연

SO-101 로봇 모델, 그리퍼 접촉, 카메라 관측 및 LeRobot 학습 구조를 통합하는 데 예상보다 많은 시간이 소요될 수 있다.

초기에는 전체 Pick-and-Stack 태스크를 구현하지 않고, 단일 블록 Pick-and-Place 환경부터 구성한다. 기본 동작과 데이터 수집 가능성을 먼저 검증한 후 단계적으로 환경을 확장한다. Simulation 구축 비용에 비해 성능 개선 효과가 낮은 경우에는 실제 데이터 수집과 Human-in-the-Loop 학습을 우선 적용한다.

7.3.3 강화학습 보상 설계 문제

최종 성공 여부만 보상으로 사용하면 성공 경험이 부족해 학습이 진행되지 않을 수 있다. 반대로 중간 보상을 지나치게 많이 설정하면 로봇이 실제 목표와 다른 행동을 학습할 수 있다.

따라서 거리 감소, 파지 성공, 목표 도달과 같은 단순한 보상부터 적용하고, 정책 행동을 확인하면서 충돌, 낙하, 불필요한 움직임에 대한 패널티를 순차적으로 추가한다. Pick-and-Stack 태스크에는 작업 단계와 진행도를 반영한 보상 방식을 검토한다.

8 구성원별 역할 및 진척도

구성원	주요 담당 분야	향후 수행 계획
여재언	정책 모델 학습 및 강화학습 설계	• ACT, Diffusion Policy, SmolVLA의 성공률 및 추론 성능 비교 • 최종 적용 정책 선정 • 거리 감소, 파지 성공, 목표 영역 도달 등을 반영한 보상 함수 설계 • 모방학습 정책을 초기 정책으로 활용한 강화학습 Fine-tuning 수행
옥소미	로봇 하드웨어 구축, 데이터 수집 및 실험	• 낮은 각도의 Top Camera와 Wrist Camera를 활용한 추가 데이터 수집 • 블록 위치와 방향을 다양화한 학습 데이터 보강 • 관절 체결 및 캘리브레이션 점검 절차 정립 • 정책 실행 중 사람의 개입과 실패 복구 동작을 포함하는 DAgger 데이터 수집 • 최종 정책의 실제 환경 반복 평가 수행
문여원	시뮬레이션 환경 구축 및 시스템 통합	• 블록의 위치·방향·간격을 변화시키는 Simulation Episode 생성 • 조명, 배경, 카메라 위치 및 물체 색상을 변경하는 Visual Domain Randomization 적용 • 질량, 마찰계수, 관절 감쇠 및 제어 지연을 변경하는 Dynamics Randomization 적용 • Simulation 데이터를 LeRobot Dataset 형식으로 변환 및 전처리 • Real-only, Sim-only, Sim+Real 정책의 성능 비교 및 Sim-to-Real 결과 분석

8.1 공동 수행 업무

구성원별 담당 분야 외에도 다음 업무는 실험 결과를 공유하며 공동으로 수행하고 있다.

- 카메라 배치와 정책 모델 조합에 따른 로봇 동작 성능 분석
- Pick-and-Place 및 Pick-and-Stack 성공·실패 기준 수립
- 파지 실패, 블록 낙하, 목표 위치 이탈 등의 실패 사례 분석
- 실험 결과에 따른 데이터 추가 수집 및 모델 재학습
- 최종 정책의 성공률, 수행 시간, 파지 실패율 및 적재 안정성 평가
- 최종 시스템 안정화와 보고서 및 발표자료 작성

8.2 전체 진척도

현재까지 실물 로봇과 Tele-operation 환경, RTX 4090 기반 학습 환경, Jetson Orin Nano와 정책 서버 간 통신 구조 및 MuJoCo 기본 Simulation 환경의 구축을 완료하였다. 또한 Pick-and-Place 데이터 100 에피소드와 Pick-and-Stack 데이터 50 에피소드를 확보하여 SmolVLA와 ACT 기반 초기 학습 및 실험을 수행하였다.

초기 정책을 통해 단순한 블록 배치 조건에서는 태스크 수행 가능성을 확인하였으며, 카메라 구성과 모델 변경을 통해 추론 지연을 감소시키는 성과를 확보하였다. 다만 어려운 위치의 블록에 대한 파지 실패, 최종 블록 Release 실패 및 환경 변화에 대한 일반화 성능은 추가 개선이 필요하다.

향후에는 각 구성원의 담당 영역을 연계하여 Simulation 데이터 생성, Domain Randomization, Human-in-the-Loop 기반 복구 데이터 수집 및 강화학습을 순차적으로 적용할 예정이다. 최종적으로 Real-only, Sim-only, Sim+Real 및 강화학습 정책을 동일한 평가 환경에서 비교하여 가장 안정적이고 효율적인 정책을 선정한다.